

Codage du texte

Comment le texte est-il représenté dans un ordinateur ?

A	é	愛	😎	🦴
$(41)_{16}$	$(C3A9)_{16}$	$(E6849B)_{16}$	$(F09F988E)_{16}$	$(F0938080)_{16}$

Nicholas Wolff · CC BY-SA 4.0

Sommaire

Différents codages de texte en nombres

Codage ne veut pas dire chiffrement.

1

Codages du texte

ASCII, Character Sets, Unicode

2

Malentendus

Sur les conventions

Un codage par signal électrique, antérieur à l'informatique

Activité · 2 min

Connaissez-vous déjà des manières de coder du texte pour le transmettre à travers un câble électrique ?

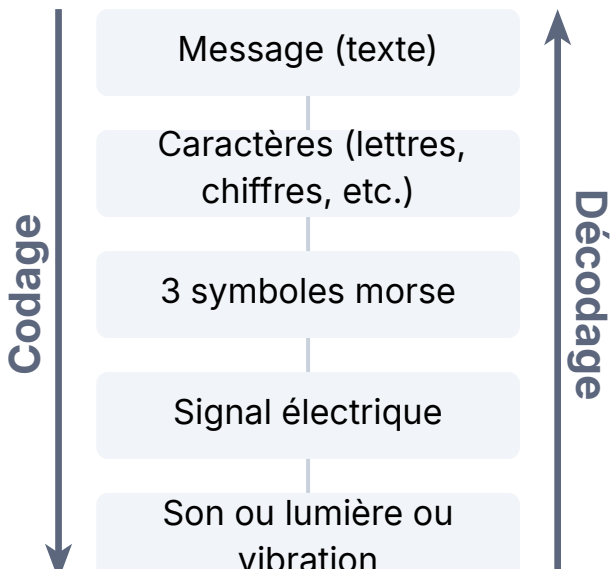
morse.mp3

Exemple : le morse

Code morse international

1. Un point dure une unité.
2. Un trait dure trois unités.
3. Entre les éléments d'une même lettre : une unité.
4. Entre deux lettres : trois unités.
5. Entre deux mots : sept unités.

A	·−	N	−·	0	−−−−−
B	−···	O	−−−	1	·−−−−
C	−·−·	P	·−−·	2	··−−−
D	−··	Q	−−·−	3	···−−
E	·	R	·−·	4	····−
F	··−·	S	···	5	·····
G	−−·	T	−	6	−····
H	····	U	··−	7	−−···
I	··	V	···−	8	−−−··
J	·−−−	W	·−−	9	−−−−·
K	−·−	X	−··−		
L	·−··	Y	−·−−		
M	−−	Z	−−··		



Le texte dans un ordinateur et entre ordinateurs

- Dans un ordinateur, tout est représenté en binaire (avec des 0 et des 1).
- Nous savons déjà comment représenter les nombres en binaire.
- Pour représenter les lettres d'un texte, il suffit de trouver une **convention** pour faire correspondre chaque lettre à un nombre.

ASCII

American **S**tandard **C**ode for **I**nformation **I**nterchange – Standard créé en 1963

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
1_	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2_	*SP*	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL

Pour **coder** un caractère :

- On trouve le premier symbole hexadécimal à gauche de la ligne contenant la lettre.
- On trouve le deuxième symbole hexadécimal en haut de la colonne contenant la lettre.

Par exemple pour coder K :

K est sur la ligne **4_**, colonne **B**.

Donc K se code **4B** en hexadécimal.

ASCII : exercices

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
1_	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2_	*SP*	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL

Binaire	Hexa
0000	0
0001	1
0010	2
0011	3
0100	4
0101	5
0110	6
0111	7
1000	8
1001	9
1010	A
1011	B
1100	C
1101	D
1110	E
1111	F

Activité · 6 min

1. Coder les lettres de votre prénom en hexadécimal à l'aide de la table.
2. Décoder ce texte binaire (convertir vers l'hexadécimal en utilisant la table de droite, puis de l'hexadécimal au texte en utilisant la table ASCII) : `01010011 01001111 01010011`
3. Combien de bits sont utilisés par caractère ?
4. Peut-on coder la phrase « Un âne est-il passé par là ? » à l'aide de cette table (justifier la réponse) ?

ASCII : exercices

1. Coder les lettres de votre prénom en hexadécimal à l'aide de la table.

On utilise la table ASCII pour trouver le nombre hexadécimal correspondant à chaque lettre. Par exemple, « Alan » devient la séquence de 4 octets : `41 6C 61 6E`

2. Décoder ce texte binaire.

- On commence par convertir chaque octet en hexadécimal.
- Puis on cherche chaque caractère dans la table ASCII.

Binaire	`0101'0011`	`0100'1111`	`0101'0011`
Hexadécimal	`5 3`	`4 F`	`5 3`
Caractères	**S**	**O**	**S**

3. Combien de bits sont utilisés par caractère ?

Le plus grand caractère de la table ASCII apparaît en bas à droite. Son numéro est $(7F)_{16}$, ce qui vaut $(0111'1111)_2$, ce qui est équivalent à $(111'1111)_2$, un nombre binaire sur 7 bits.

Donc : en ASCII, **7 bits** sont utilisés par caractère.

4. Peut-on coder la phrase « Un âne est-il passé par là ? » à l'aide de cette table (justifier la réponse) ?

Non, car on n'a aucun moyen de coder les caractères â, é et à. Le standard ASCII est conçu pour l'anglais.

Character Sets

- ASCII est conçu pour l'anglais : impossible d'y coder â, é ou à, et encore moins le grec ou le thaï.
- ASCII n'utilise que **7 bits**, soit 128 caractères. Un octet en a **8** : 256 nombres, donc 128 de plus.
- Un **Character Set** garde la table ASCII pour les nombres de $(00)_{16}$ à $(7F)_{16}$, et utilise ceux de $(80)_{16}$ à $(FF)_{16}$ pour les caractères d'une langue ou d'un système d'écriture.
- À partir de 1987 sont créés des Character Sets : Latin 1, puis le grec, le cyrillique, l'arabe, l'hébreu, le thaï, etc.

$(00)_{16}$ à $(7F)_{16}$	$(80)_{16}$ à $(FF)_{16}$
ASCII identique dans tous les Character Sets	grec : α β Σ Ω
	thaï : ก ข ค
	etc.

Character Set : Latin 1

Le début est identique à la table ASCII.

Activité · 1 min

Quelles langues peut-on écrire avec ce codage ?

ISO/IEC 8859-1

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	SP	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	¡	¢	£	¤	¥	¦	§	¨	©	ª	«	¬	SHY	®	¯
B_	°	±	²	³	´	µ	¶	·	¸	¹	º	»	¼	½	¾	¿
C_	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
D_	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
E_	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
F_	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

Défauts des Character Sets

- Il faut se mettre d'accord en avance sur comment interpréter les nombres qu'on va échanger. Par exemple, comment sera compris le caractère grec Σ si on l'interprète dans le Character Set thaï ?
- Impossible de mélanger plusieurs langues dans un même document.
- 8 bits ne suffisent pas à représenter de nombreux systèmes d'écriture.

ISO/IEC 8859-7

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	SP	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	‘	’	£	€	₯	¦	§	¨	©	ͺ	«	¬	SHY		—
B_	°	±	²	³	΄	΅	Ά	·	Έ	Ή	Ί	»	Ό	½	Ύ	Ώ
C_	ΐ	Α	Β	Γ	Δ	Ε	Ζ	Η	Θ	Ι	Κ	Λ	Μ	Ν	Ξ	Ο
D_	Π	Ρ		Σ	Τ	Υ	Φ	Χ	Ψ	Ω	Ϊ	Ϋ	ά	έ	ή	ί
E_	ΰ	α	β	γ	δ	ε	ζ	η	θ	ι	κ	λ	μ	ν	ξ	ο
F_	π	ρ	ς	σ	τ	υ	φ	χ	ψ	ω	ϊ	ϋ	ό	ύ	ώ	

ISO/IEC 8859-11

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	SP	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	ก	ข	ฃ	ค	ฅ	ฆ	ง	จ	ฉ	ช	ซ	ฌ	ญ	ฎ	ฏ
B_	ฐ	ฑ	ฒ	ณ	ด	ต	ถ	ท	ธ	น	บ	ป	ผ	ฝ	พ	ฟ
C_	ภ	ม	ย	ร	ฤ	ล	ฦ	ว	ศ	ษ	ส	ห	ฬ	อ	ฮ	ฯ
D_	ะ	ั	า	ำ	ิ	ี	ึ	ื	ุ	ู	ฺ					฿
E_	เ	แ	โ	ใ	ไ	ๅ	ๆ	็	่	้	๊	๋	์	ํ	๎	๏
F_	๐	๑	๒	๓	๔	๕	๖	๗	๘	๙	๚	๛				

Unicode

Unicode est un *standard* informatique qui permet des échanges de textes dans différentes langues, à un niveau mondial. Il vise au codage de texte écrit en donnant à tout caractère de *n'importe quel système d'écriture* un nom et un *identifiant numérique*, et ce de manière unifiée, *quels que soient la plateforme informatique ou le logiciel utilisé*.

Le projet démarre en 1987 ; la première version est publiée en 1991.

Unicode aujourd'hui

Dans la 18ᵉ version du standard (qui date de 2026), on répertorie 172'808 caractères différents.

Nouveautés de la version 18 : blog.emojipedia.org/whats-new-in-unicode-18-0

بِسْمِ ٱللَّهِ ٱلرَّحْمَٰنِ ٱلرَّحِيمِ

? ☃ 愛 が 🍣 𓀀

Unicode : attribuer des numéros aux caractères

Le standard Unicode se contente d'attribuer un nombre à chaque caractère.

Par exemple, la phrase :

L o l ␣ Γ ␣ 🐶

... se convertit en la suite de nombres suivante :

$(4C)_{16}$ $(6F)_{16}$ $(6C)_{16}$ $(20)_{16}$ $(393)_{16}$ $(20)_{16}$ $(1F436)_{16}$

Unicode : représentation sous forme d'octets

Par exemple, la phrase :

L o l ␣ Γ ␣ 🐶

… se convertit en la suite de nombres suivante :

$(4C)_{16}$ $(6F)_{16}$ $(6C)_{16}$ $(20)_{16}$ $(393)_{16}$ $(20)_{16}$ $(1F436)_{16}$

Le nombre de bits nécessaires pour représenter chacun de ces caractères est :

7 **7** **7** **6** **10** **6** **17**

Activité · 2 min

- Combien d'*octets* faut-il pour représenter l'espace ? le L ? le Γ ? le 🐶 ?
- Comment représenter cette séquence de nombres en *octets* ? Avez-vous des propositions, des idées ?

Nécessité d’un format de transformation

UTF-8 (1992)
Unicode **T**ransformation **F**ormat – **8** bits

- Utilisé par environ 99 % des sites Web (statistique d’octobre 2026).
- Permet de coder les caractères Unicode sous forme de **séquences de un à quatre octets**.
- *(Quelques alternatives sont UTF-16 et UTF-32.)*

Sommaire

1 **Codages du texte**
ASCII, Character Sets, Unicode

2 **Malentendus**
Sur les conventions

Un bug de codage



On voulait manifestement écrire un **é**.

En UTF-8, le codage de ce caractère est $(\texttt{C3A9})_{16}$.

Activité · 2 min

Pouvez-vous trouver dans ce cours un autre type de codage de texte qui pourrait expliquer ce qu'on voit à gauche ?

Un bug de codage



On voulait manifestement écrire un **é**.

En UTF-8, le codage de ce caractère est $(\texttt{C3A9})_{16}$.

Activité

Pouvez-vous trouver dans ce cours un autre type de codage de texte qui pourrait expliquer ce qu'on voit à gauche ?

On a un problème de malentendu sur la convention utilisée pour représenter ce caractère :

- la personne qui a généré le message l'a fait en UTF-8 ;
- la personne qui a reçu le message l'a interprété comme Latin 1.

Sources

Contenu et outils

Wikipédia – Code Morse international
fr.wikipedia.org

Wikipédia – Caractère (typographie)
fr.wikipedia.org

Wikipédia – American Standard Code for Information Interchange
fr.wikipedia.org

ISO – la norme ISO 8859-1:1987, Latin 1
iso.org

Convertisseur Unicode
ri.nwolff.info

ridiculousfish – Hex Fiend
hexfiend.com

Unicode et UTF-8

Wikipédia – Unicode
fr.wikipedia.org

Unicode Consortium – l'histoire d'Unicode
unicode.org

Unicode Consortium – Unicode 1.0
unicode.org

Unicode Consortium – Unicode 18.0
unicode.org

Compart – le caractère U+00E9, é
compart.com

Wikipédia – UTF-8
fr.wikipedia.org

W3Techs – l'usage d'UTF-8 sur le Web
w3techs.com

Images

Hans Hillewaert – la pierre de Rosette (CC BY-SA 4.0)
commons.wikimedia.org

Détournement anonyme d'une couverture de *Martine* (Marcel Marlier, Casterman)