

Codage du texte

Comment le texte est-il représenté dans un ordinateur ?

A	é	愛	😎
41	C3 A9	E6 84 9B	F0 9F 98 8E

Nicholas Wolff · CC BY-SA 4.0

Sommaire

1. **Codages du texte en nombres**
   ASCII, Character Sets, Unicode, UTF-8
2. **Un problème (presque) résolu**
   Les anciens codages ont la vie dure

Un codage par signal électrique, antérieur à l'informatique

Activité · 6 min

Connaissez-vous déjà des manières de coder du texte pour le transmettre à travers un câble électrique ?

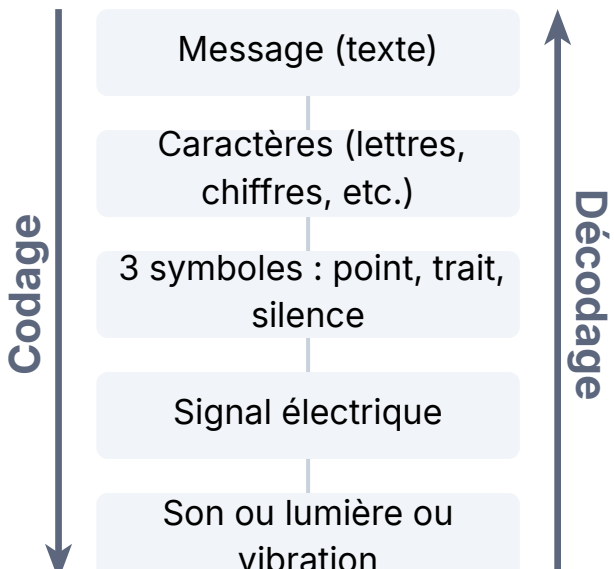
Écouter

Exemple : le morse

Code morse international

1. Un point dure une unité.
2. Un trait dure trois unités.
3. Entre les éléments d'une même lettre : une unité.
4. Entre deux lettres : trois unités.
5. Entre deux mots : sept unités.

A	•−	N	−•	0	−−−−−
B	−•••	O	−−−	1	•−−−−
C	−•−•	P	•−−•	2	••−−−
D	−••	Q	−−•−	3	•••−−
E	•	R	•−•	4	••••−
F	••−•	S	•••	5	•••••
G	−−•	T	−	6	−••••
H	••••	U	••−	7	−−•••
I	••	V	•••−	8	−−−••
J	•−−−	W	•−−	9	−−−−•
K	−•−	X	−••−		
L	•−••	Y	−•−−		
M	−−	Z	−−••		



Le texte dans un ordinateur et entre ordinateurs

- Un texte est une séquence de caractères. Un caractère : une lettre, un chiffre, un signe de ponctuation, l'espace, un retour à la ligne…
- Dans un ordinateur, tout est représenté en binaire (avec des 0 et des 1).
- Nous savons déjà comment représenter les nombres en binaire.
- Pour représenter un texte, il suffit de trouver une **convention** pour faire correspondre chaque caractère à un nombre.
- Le texte devient alors une séquence de nombres, un par caractère, qu'on lit l'un après l'autre.

Nous allons explorer plusieurs de ces conventions.

Activité · 2 min

Avez-vous une idée de convention pour faire correspondre chaque caractère à un nombre ?

ASCII

American **S**tandard **C**ode for **I**nformation **I**nterchange – Standard créé en 1963

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
1_	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL

Caractères de contrôle, ne s'affichent pas.

␣ : l'espace.

Pour **coder** un caractère : sa ligne donne le premier symbole hexadécimal, sa colonne le deuxième.

Par exemple K : ligne **4_**, colonne **B**, K se code **4B**.

Pour **décoder** un nombre hexadécimal : le premier symbole donne la ligne, le deuxième la colonne.

Par exemple **61** : ligne **6_**, colonne **1**, c'est le caractère a.

ASCII : exercices

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
1_	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL

Binaire	Hexa
0000	0
0001	1
0010	2
0011	3
0100	4
0101	5
0110	6
0111	7
1000	8
1001	9
1010	A
1011	B
1100	C
1101	D
1110	E
1111	F

Activité · 6 min

1. Coder les lettres de votre prénom en hexadécimal à l'aide de la table.
2. Décoder ce texte binaire (convertir vers l'hexadécimal en utilisant la table de droite, puis de l'hexadécimal au texte en utilisant la table ASCII) : `01010011 01001111 01010011`
3. Combien de bits sont utilisés par caractère ?
4. Peut-on coder la phrase « Un âne est-il passé par là ? » à l'aide de cette table (justifier la réponse) ?

ASCII : exercices

1. Coder les lettres de votre prénom en hexadécimal à l'aide de la table.

On utilise la table ASCII pour trouver le nombre hexadécimal correspondant à chaque lettre. Par exemple, « Alan » devient la séquence de 4 octets : `41 6C 61 6E`

2. Décoder ce texte binaire.

- En ASCII, chaque caractère occupe un octet : on découpe le texte tous les 8 bits.
- On commence par convertir chaque octet en hexadécimal.
- Puis on cherche chaque caractère dans la table ASCII.

Binaire	`0101'0011`	`0100'1111`	`0101'0011`
Hexadécimal	`5 3`	`4 F`	`5 3`
Caractères	**S**	**O**	**S**
Texte		**SOS**	

3. Combien de bits sont utilisés par caractère ?

Le dernier caractère de la table ASCII, en bas à droite, a le plus grand nombre : $(7F)_{16}$, soit $(0111'1111)_2$. Même pour lui, le bit de gauche vaut 0 : ce bit n'est jamais utilisé. Il reste $(111'1111)_2$, sur 7 bits.

Donc : en ASCII, **7 bits** sont utilisés par caractère.

4. Peut-on coder la phrase « Un âne est-il passé par là ? » à l'aide de cette table (justifier la réponse) ?

Non, car on n'a aucun moyen de coder les caractères â, é et à. Le standard ASCII est conçu pour l'anglais.

Character Sets

- ASCII est conçu pour l'anglais : impossible d'y coder â, é ou à, et encore moins le grec ou le thaï.
- À partir de 1987 sont créés des **Character Sets** : Latin 1, puis le grec, le cyrillique, l'arabe, l'hébreu, le thaï, etc.
- ASCII n'utilise que **7 bits**, soit 128 caractères. Un octet en a **8** : 256 nombres, donc 128 de plus.
- Un Character Set **étend** ASCII : il garde la table ASCII pour les nombres de $(00)_{16}$ à $(7F)_{16}$, et y ajoute, de $(80)_{16}$ à $(FF)_{16}$, les caractères d'une langue ou d'un système d'écriture.

$(00)_{16}$ à $(7F)_{16}$	$(80)_{16}$ à $(FF)_{16}$
ASCII	grec : α β Σ Ω
identique dans tous les Character Sets	thaï : ก ข ค
	etc.

Character Set : Latin 1

Le Character Set Latin 1 :

- De $(00)_{16}$ à $(7F)_{16}$: la table ASCII, inchangée.
- De $(80)_{16}$ à $(9F)_{16}$: d'autres caractères de contrôle, qui ne s'affichent pas.
- De $(A0)_{16}$ à $(FF)_{16}$: les caractères ajoutés, des lettres accentuées et d'autres symboles.

Activité · 1 min

Quelles langues peut-on écrire avec ce codage ?

Et quelles langues ne peut-on pas écrire ?

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	¡	¢	£	¤	¥	¦	§	¨	©	ª	«	¬	SHY	®	¯
B_	°	±	²	³	´	µ	¶	·	¸	¹	º	»	¼	½	¾	¿
C_	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
D_	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
E_	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
F_	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

En gris : caractères de contrôle, ne s'affichent pas.

Défauts des Character Sets

Character Set grec

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	‘	’	£	€	₯	¦	§	¨	©	¸	«	¬	SHY		—
B_	°	±	²	³	΄	΅	Ά	·	Έ	Ή	Ί	»	Ό	½	Ύ	Ώ
C_	ΐ	A	B	Γ	Δ	E	Z	H	Θ	I	K	Λ	M	N	Ξ	O
D_	Π	P		Σ	T	Y	Φ	X	Ψ	Ω	Ϊ	Ϋ	ά	έ	ή	ί
E_	ΰ	α	β	γ	δ	ε	ζ	η	θ	ι	κ	λ	μ	ν	ξ	ο
F_	π	ρ	ς	σ	τ	υ	φ	χ	ψ	ω	ϊ	ϋ	ό	ύ	ώ	

Character Set thaï

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	ก	ข	ฃ	ค	ฅ	ฆ	ง	จ	ฉ	ช	ซ	ฌ	ญ	ฎ	ฏ
B_	ฐ	ฑ	ฒ	ณ	ด	ต	ถ	ท	ธ	น	บ	ป	ผ	ฝ	พ	ฟ
C_	ภ	ม	ย	ร	ฤ	ล	ฦ	ว	ศ	ษ	ส	ห	ฬ	อ	ฮ	ฯ
D_	ะ	ั	า	ำ	ิ	ี	ึ	ื	ุ	ู	ฺ					฿
E_	เ	แ	โ	ใ	ไ	ๅ	ๆ	็	่	้	๊	๋	์	ํ	๎	๏
F_	๐	๑	๒	๓	๔	๕	๖	๗	๘	๙	๚	๛				

Activité · 2 min

1. Comment sera compris le caractère grec Σ si on l’interprète dans le Character Set thaï ?
2. Peut-on coder avec un même Character Set le texte « Socrate s’écrit Σωκράτης en grec » ?
3. Peut-on faire un Character Set pour le chinois ?

Défauts des Character Sets

Character Set grec

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	‘	’	£	€	₯	¦	§	¨	©	¸	«	¬	SHY		—
B_	°	±	²	³	΄	΅	Ά	·	Έ	Ή	Ί	»	Ό	½	Ύ	Ώ
C_	ΐ	A	B	Γ	Δ	E	Z	H	Θ	I	K	Λ	M	N	Ξ	O
D_	Π	P		Σ	T	Y	Φ	X	Ψ	Ω	Ϊ	Ϋ	ά	έ	ή	ί
E_	ΰ	α	β	γ	δ	ε	ζ	η	θ	ι	κ	λ	μ	ν	ξ	ο
F_	π	ρ	ς	σ	τ	υ	φ	χ	ψ	ω	ϊ	ϋ	ό	ύ	ώ	

Character Set thaï

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0_																
1_																
2_	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3_	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4_	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5_	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6_	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7_	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	
8_																
9_																
A_	NBSP	ก	ข	ฃ	ค	ฅ	ฆ	ง	จ	ฉ	ช	ซ	ฌ	ญ	ฎ	ฏ
B_	ฐ	ฑ	ฒ	ณ	ด	ต	ถ	ท	ธ	น	บ	ป	ผ	ฝ	พ	ฟ
C_	ภ	ม	ย	ร	ฤ	ล	ฦ	ว	ศ	ษ	ส	ห	ฬ	อ	ฮ	ฯ
D_	ะ	ั	า	ำ	ิ	ี	ึ	ื	ุ	ู	ฺ					฿
E_	เ	แ	โ	ใ	ไ	ๅ	ๆ	็	่	้	๊	๋	์	ํ	๎	๏
F_	๐	๑	๒	๓	๔	๕	๖	๗	๘	๙	๚	๛				

- Il faut se mettre d’accord en avance sur comment interpréter les nombres qu’on va échanger : le nombre $(D3)_{16}$ est Σ en grec, mais ๎ก en thaï.
- Impossible de mélanger dans un même document des langues de Character Sets différents, comme le français et le grec.
- 8 bits ne suffisent pas à représenter de nombreux systèmes d’écriture : le chinois, le japonais, le coréen ont chacun leur codage à plusieurs octets, incompatibles entre eux.

Unicode

Unicode est un *standard* informatique qui permet des échanges de textes dans différentes langues, à un niveau mondial. Il vise au codage de texte écrit en donnant à tout caractère de *n'importe quel système d'écriture* un nom et un *identifiant numérique*, et ce de manière unifiée, *quels que soient la plateforme informatique ou le logiciel utilisé*.

Cet identifiant, le **nombre Unicode** du caractère, va de $(0)_{16}$ à $(10FFFF)_{16}$.

Le projet démarre en 1987 ; la première version est publiée en 1991.

Unicode aujourd'hui

Dans la 18ᵉ version du standard (qui date de 2026), on répertorie 172'808 caractères différents.

A é Σ ω ع א 7 €

愛 が 한 پ ? ☃ 🐙 ᚻ



Nouveautés de la version 18 : blog.emojipedia.org/whats-new-in-unicode-18-0

Unicode : attribuer des nombres aux caractères

Le standard Unicode se contente d'attribuer un nombre à chaque caractère.

Par exemple, la phrase :

â n e ‰ ␣ 🐶

… se convertit en la séquence de nombres suivante :

$(E2)_{16}$ $(6E)_{16}$ $(65)_{16}$ $(2030)_{16}$ $(20)_{16}$ $(1F436)_{16}$

Mais un ordinateur ne stocke et n'échange que des **octets** : il faudra, à un moment, représenter ces nombres sous forme d'octets.

Unicode : représentation sous forme d'octets

â	n	e	‰	␣	🐶
$(E2)_{16}$	$(6E)_{16}$	$(65)_{16}$	$(2030)_{16}$	$(20)_{16}$	$(1F436)_{16}$
1110'0010	110'1110	110'0101	10'0000'0011'0000	10'0000	1'1111'0100'0011'0110

Le nombre de **bits** nécessaires pour représenter chacun de ces caractères est :

8	7	7	14	6	17

Activité · 2 min

- Combien d'**octets** faut-il pour représenter l'espace ? le n ? le â ? le ‰ ? le 🐶 ?
- Comment représenter cette séquence de nombres en **octets** ? Avez-vous des propositions, des idées ?

Une proposition (trop) simple

Proposition : écrire chaque nombre sur le moins d'octets possible, puis mettre les octets bout à bout.

â	n	e	‰	␣	🐶
$(E2)_{16}$	$(6E)_{16}$	$(65)_{16}$	$(2030)_{16}$	$(20)_{16}$	$(1F436)_{16}$
E2	6E	65	20 30	20	01 F4 36

La phrase devient la séquence d'octets : `E2 6E 65 20 30 20 01 F4 36`

Activité · 2 min

En recevant seulement cette séquence d'octets, peut-on retrouver la phrase ?

Une proposition (trop) simple

Proposition : écrire chaque nombre sur le moins d'octets possible, puis mettre les octets bout à bout.

â	n	e	‰	␣	🐶
$(E2)_{16}$	$(6E)_{16}$	$(65)_{16}$	$(2030)_{16}$	$(20)_{16}$	$(1F436)_{16}$
E2	6E	65	20 30	20	01 F4 36

La phrase devient la séquence d'octets : **E2 6E 65 20 30 20 01 F4 36**

Non : rien dans la séquence n'indique où un caractère s'arrête. Les octets du ‰, par exemple, peuvent se lire de deux façons :

$$20\ 30 \rightarrow (2030)_{16} \rightarrow ‰$$

$$20 \mid 30 \rightarrow (20)_{16}\ (30)_{16} \rightarrow ␣\ 0$$

Il faut une façon d'écrire les nombres qui dise où chaque caractère commence et s'arrête.

Un format de transformation : UTF-8

Il faut donc une règle pour écrire chaque nombre Unicode en octets, qui permette de relire la séquence sans ambiguïté : un *format de transformation*.

UTF-8 (1992)
Unicode **T**ransformation **F**ormat – **8** bits

- Comme dans notre proposition, un caractère prend un nombre variable d'octets, ici de **un à quatre** ; mais chaque octet indique sa place dans le caractère, et la séquence se relit sans ambiguïté.
- D'autres formats existent : par exemple UTF-32 qui écrit chaque caractère sur 4 octets (facile à relire, mais 4 fois plus long qu'en UTF-8 pour un texte simple)

Retour à la page de titre

Voici la ligne de la page de titre : chaque caractère au-dessus de ses octets UTF-8.



Chaque caractère, quel que soit son système d'écriture, a un nombre Unicode, et UTF-8 écrit ce nombre en 1 à 4 octets.

Sommaire

1 **Codages du texte en nombres**
ASCII, Character Sets, Unicode, UTF-8

2 **Un problème (presque) résolu**
Les anciens codages ont la vie dure

De l’ASCII à UTF-8

ASCII
1963
128 caractères : l’anglais.
Ni accents, ni autres systèmes d’écriture.

↓

Character Sets
1987
256 caractères, une table par système d’écriture ou groupe de langues.
Une table à la fois, et il faut savoir laquelle.

↓

Unicode
1991
Un nombre pour chaque caractère de tous les systèmes d’écriture.
Des nombres, pas encore des octets.

↓

UTF-8
1992
Ces nombres en octets, dans une séquence qui se relit sans ambiguïté.

UTF-8 aujourd’hui

99 %

des sites Web utilisent UTF-8

(statistique d’octobre 2026)

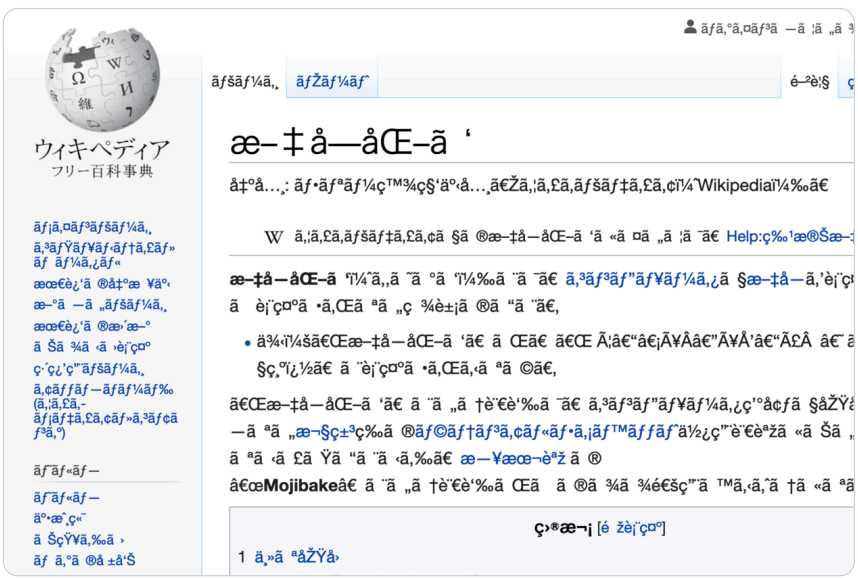
Le problème du texte est donc résolu ? Presque : il reste des endroits où l’on n’écrit encore qu’en ASCII, et des malentendus.

L’ASCII est encore partout

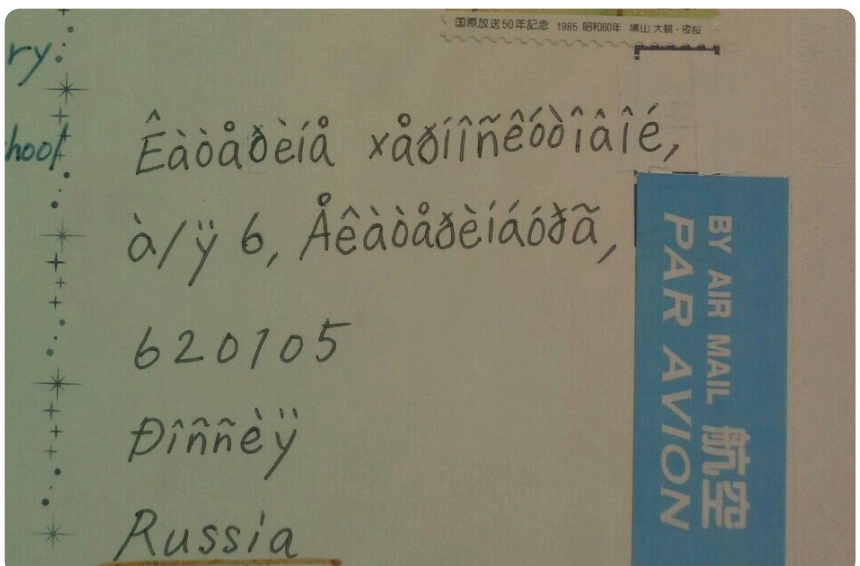
- **Billets d’avion** : les systèmes de réservation des compagnies aériennes n’admettent que les lettres A à Z. Un billet ne peut pas porter le nom MÜLLER.
- **Passeports** : la zone lisible par machine du passeport n’admet que les lettres A à Z, les chiffres et le signe <. Le passeport porte donc deux noms : MÜLLER en clair, MUELLER dans cette zone. C’est ce second nom que le billet doit reprendre.
- **Adresses e-mail** : les adresses avec accents, comme `rené@exemple.ch`, existent depuis 2012, mais peu de services les acceptent : on écrit `rene@exemple.ch`.
- **Adresses Web** : les noms de domaine avec accents existent, mais ils sont rares et convertis en ASCII : l’Académie française est sur `academie-francaise.fr`, où l’on lirait « frankaise ». Dans le reste de l’adresse, un caractère non ASCII s’écrit avec ses octets UTF-8, chacun précédé de % : `fr.wikipedia.org/wiki/Français` devient `…/wiki/Fran%C3%A7ais`.

Mojibake

Le texte illisible qu'on obtient en lisant des octets avec la mauvaise convention a un nom : en japonais *mojibake* (文字化け, « caractères transformés »), en russe *krakozyabry* (кракозябры).



Wikipédia en japonais, écrit en UTF-8, lu comme du Latin 1.



Une carte pour la Russie : l'adresse, écrite dans le Character Set russe, s'affichait au Japon comme du Latin 1, et a été recopiée à la main telle quelle. Elle est arrivée.

Sources

Contenu et outils

Wikipédia – Code Morse international
fr.wikipedia.org

Wikipédia – Caractère (typographie)
fr.wikipedia.org

Wikipédia – American Standard Code for Information Interchange
fr.wikipedia.org

ISO – la norme ISO 8859-1:1987, Latin 1
iso.org

Wikipédia – ISO/CEI 8859
fr.wikipedia.org

Convertisseur Unicode
ri.nwolff.info

ridiculousfish – Hex Fiend
hexfiend.com

Unicode et UTF-8

Wikipédia – Unicode
fr.wikipedia.org

Unicode Consortium – l'histoire d'Unicode
unicode.org

Unicode Consortium – Unicode 1.0
unicode.org

Unicode Consortium – Unicode 18.0
unicode.org

Compart – le caractère U+00E9, é
compart.com

Wikipédia – UTF-8
fr.wikipedia.org

W3Techs – l'usage d'UTF-8 sur le Web
w3techs.com

L'ASCII encore là, les malentendus

OACI – Doc 9303, documents de voyage lisibles à la machine
icao.int

IETF – RFC 6530, les adresses e-mail internationalisées (2012)
rfc-editor.org

Wikipédia – Mojibake
fr.wikipedia.org

Microsoft – bulletin MS00-078, la faille d'IIS (2000)
learn.microsoft.com

Images

Nationaal Archief – les caractères d'une machine à écrire japonaise, 1938 (sans restriction connue)
commons.wikimedia.org

Wikimedia Foundation – l'article « mojibake » de Wikipédia en japonais, mal décodé (CC BY-SA 4.0)
commons.wikimedia.org

Katerina Chernoskutova – une carte postale envoyée en Russie (domaine public)
commons.wikimedia.org

Twitter et contributeurs (Twemoji) – les émojis (CC BY 4.0)
github.com