

Les moteurs de recherche

Trouver une page parmi des milliards, en moins d'une seconde

Nicholas Wolff · CC BY-SA 4.0

Sommaire

1

Utiliser un moteur de recherche

À quoi il sert, lesquels, comment s’en servir

2

Comment ça marche ?

Exploration, indexation, classement, personnalisation

3

Et l’IA ?

Une question ouverte

À quoi sert un moteur de recherche ?

Trouver des **ressources** à partir d'une **requête** de quelques mots : des pages web, mais aussi des images, des vidéos, des fichiers, des livres, des applications…

Des dizaines de moteurs de recherche

Google
le plus utilisé

Bing
de Microsoft

Yahoo
l'un des plus anciens (1994)

DuckDuckGo
dit ne pas vous pister

Qwant
européen

… et bien d'autres.

Activité · 4 min

Sur gs.statcounter.com, quelle part des recherches revient à chaque moteur de recherche, dans le monde ? Et en Chine ? En Russie ?

Comment s'en servir ?

1. Taper dans la barre d'adresse du navigateur : elle accepte une URL ou une recherche.

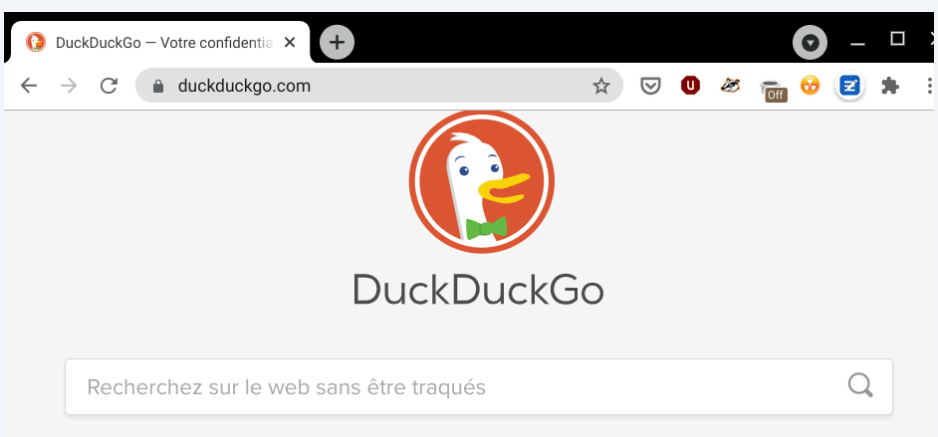
← → ↻ `fr.wikipedia.org/wiki/Olcades`

→ **une URL** : le navigateur ouvre la page.

← → ↻ **recette pizza**

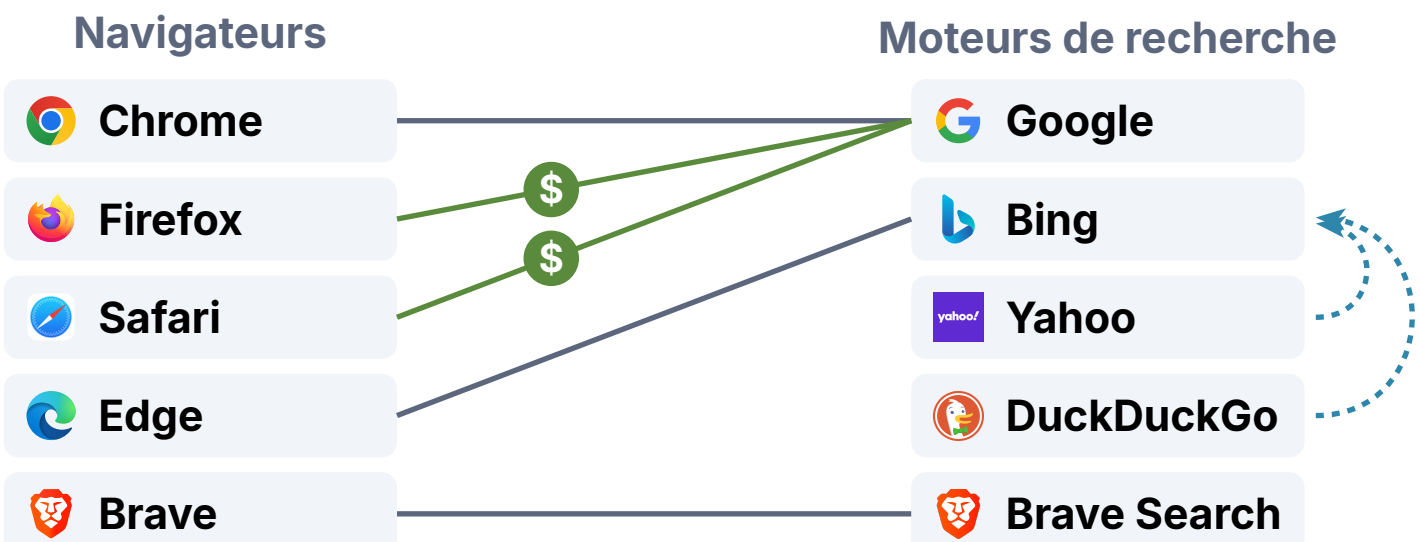
→ **une recherche** : le navigateur l'envoie au moteur de recherche.

2. Aller sur le site du moteur de recherche, et y taper la requête. Beaucoup de navigateurs s'ouvrent directement sur un moteur de recherche.



Le moteur de recherche par défaut

La barre d'adresse envoie les recherches au moteur de recherche par défaut du navigateur.



Sommaire

1

Utiliser un moteur de recherche

À quoi il sert, lesquels, comment s’en servir

2

Comment ça marche ?

Exploration, indexation, classement, personnalisation

3

Et l’IA ?

Une question ouverte

Comment ça marche ?

Question · 2 min

À votre avis, comment un moteur de recherche fait-il ?

Plus d’un milliard de sites web, des centaines de milliards de pages… et une réponse en moins d’une seconde.

Comment ça marche ?

À votre avis, comment un moteur de recherche fait-il ? Plus d'un milliard de sites web, des centaines de milliards de pages… et une réponse en moins d'une seconde.

Avant la recherche, en permanence

Au moment de la recherche

Exploration

Un robot (crawler) suit les liens de page en page et les télécharge.

→

Indexation

Pour chaque mot, la liste des pages qui le contiennent.

→

Classement

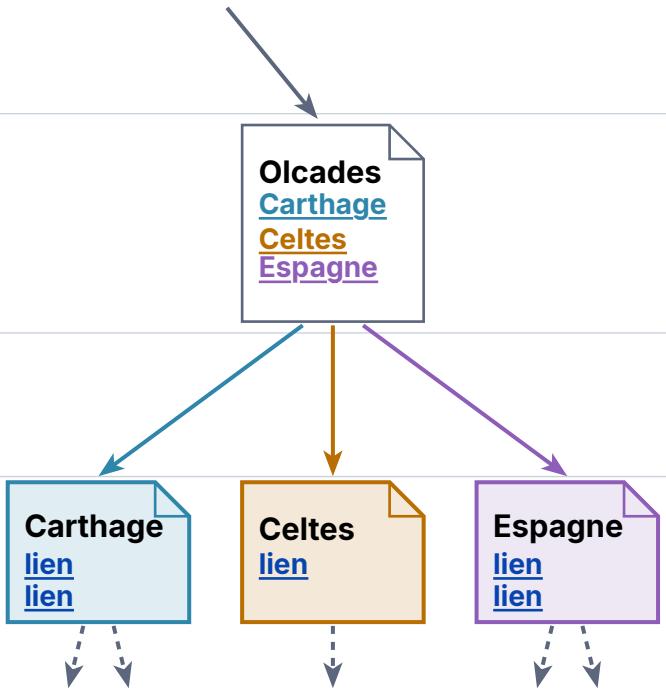
PageRank : quelles pages sont les plus importantes ?

→

Personnalisation

Votre profil (cookies, compte, lieu) modifie les résultats… et les publicités.

Le robot d'exploration



Le robot arrive à une page nouvelle, par un lien depuis un autre site, ou par déclaration explicite.

Le robot lit la page, analyse le contenu, et indexe les mots de la page, en tenant compte de leur position et autres attributs.

Le robot détecte tous les liens hypertexte de la page, et ajoute ces pages à son plan de travail.

Le robot poursuit son chemin vers les pages suivantes.

Exemple, depuis fr.wikipedia.org/wiki/Olcades.

Les robots dans le journal du serveur

Le robot fait des requêtes HTTP, comme un navigateur. Dans le journal du serveur du gymnase, un robot et un humain demandent la même page :

Un robot : Googlebot

```
66.249.68.2 [16/Oct/2026:07:26:36] "GET /robots.txt HTTP/1.1" 200
"Mozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html)"

66.249.68.2 [16/Oct/2026:07:31:07] "GET / HTTP/1.1" 200
"Mozilla/5.0 (Linux; Android 6.0.1; … Googlebot/2.1; +http://www.google.com/bot.html)"
```

Un humain : Firefox sur Mac

```
193.5.249.20 [16/Oct/2026:11:15:20] "GET / HTTP/1.1" 200
"Mozilla/5.0 (Macintosh; Intel Mac OS X 10.15; rv:140.0) Gecko/20100101 Firefox/140.0"
```

● adresse IP du client ● date et heure ● méthode et URL ● code de statut ● agent utilisateur

L'index

Index dans un livre de maths.

Question · 2 min

Quelle en est l'utilité ?

Comment feriez-vous pour chercher une information sans index ?

Par exemple « Racine ».

Q

Quantificateur 1115
Quantité conjuguée 1194

R

Racine
- *n*-ième d'un nombre complexe 17
- *n*-ième de l'unité 17
- carrée d'un nombre complexe 19
- d'ordre *p* 760
- d'un polynôme 759
- double 760
- multiple 760
- simple 760

Rang
- d'un système linéaire 965
- d'une application linéaire 895
- d'une famille de vecteurs 895
- d'une matrice 953

Réciproque
- du théorème de Thalès 1099

Réflexion 1056, 1094
Règle
- de l'Hospital 487
- de Sarrus 110, 958, 1026

Règles
- de calculs avec les matrices 938

Régulier
- point 219

Rotation 22
- décompositon 1062
- matrice 1065
- vectorielle 1061

Rotationnel 689

S

Scalaire 830
Second membre
- d'un système linéaire 965

Segment 329, 1088
Série
- géométrique 352, 711
- géométrique complexe 641

Similitude 1097
- directe 1097

Similitude directe 23
Simson
- Droite de 89

Sinus 145
- hyperbolique 151

Solution
- d'une équation différentielle linéaire du premier ordre 184
- d'une équation différentielle linéaire du second ordre 195

Somme
- binômiale 1144
- de Newton 1163
- de Riemann 528

Fabriquer l'index

Pour chaque mot, la liste des pages qui le contiennent :

Les pages

Page 1
La recette de la pizza

Page 2
Une pizza napolitaine

Page 3
La recette de la sauce napolitaine

Page 4
Histoire de la pizza

découpage en mots →

L'index inversé

Mot	Pages
la	1, 3, 4
recette	1, 3
de	1, 3, 4
pizza	1, 2, 4
une	2
napolitaine	2, 3
sauce	3
histoire	4

Chercher dans l’index

Recherche « recette pizza » :

1. Découper la requête en mots : **recette** · **pizza**
2. Chercher la liste de chaque mot dans l’index :
   recette → 1, 3 ; **pizza** → 1, 2, 4
3. Garder les pages présentes dans toutes les listes :
   page 1

L’index inversé

Mot	Pages
la	1, 3, 4
recette	1, 3
de	1, 3, 4
pizza	1, 2, 4
une	2
napolitaine	2, 3
sauce	3
histoire	4

Fabriquer l’index : les suites de mots

Chercher mot par mot ne suffit pas pour une expression : « pomme de terre » trouverait aussi une page qui parle d’une pomme tombée de l’arbre sur la terre.

On indexe donc aussi des **suites de mots** (n-grammes), pour trouver plus facilement des mots composés, des expressions, des morceaux de phrases.

Par exemple, dans « purée de pomme de terre » :

1 mot	purée · de · pomme · de · terre
2 mots	purée de · de pomme · pomme de · de terre
3 mots	purée de pomme · de pomme de · **pomme de terre**

Un index : lent à construire, rapide à lire

Ajouter une page à l'index prend du temps.

Chercher dans l'index en fait gagner beaucoup.

Question · 1 min

Perdre du temps en construisant l'index, pour en gagner à chaque recherche : est-ce une bonne idée ?

Un index : lent à construire, rapide à lire

Ajouter une page à l'index prend du temps.

Chercher dans l'index en fait gagner beaucoup.

Perdre du temps en construisant l'index, pour en gagner à chaque recherche : est-ce une bonne idée ?

Oui : on n'est pas pressé quand on indexe le Web, mais on l'est quand on cherche. Aussi à cause de ces chiffres :

≈ 400 milliards
de pages dans l'index de Google (2020)

Plus de 13 milliards
de recherches Google par jour

Classer les pages

Pourquoi classer ?

« pizza » sur Google : environ

1'090'000'000

résultats, en 0,40 seconde. Lesquels montrer en premier ?

Question · 2 min

Des idées de comment faire ?

Le classement se prépare à l'avance, avant toute recherche.

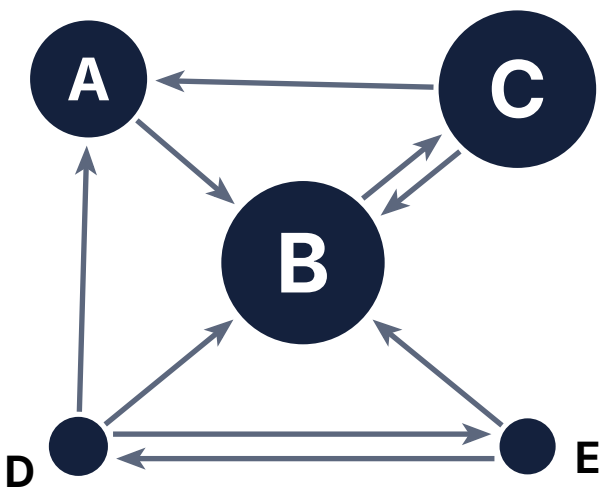
Classer : l’algorithme PageRank

Larry Page et Sergey Brin, 1996 — à l’origine de Google

Un lien de A vers B, c’est A qui recommande B : le PageRank de B augmente.

Un lien venant d’une page importante compte davantage. Mieux vaut un lien depuis la page d’accueil de Google que depuis le site de votre petit cousin !

Le PageRank de chaque page est calculé à l’avance, une fois pour toutes les recherches.

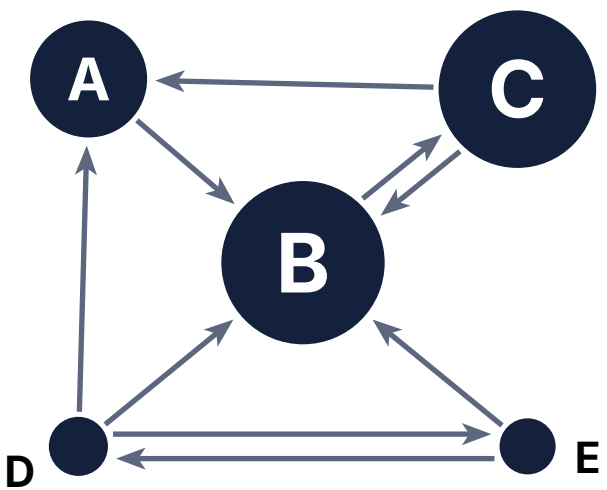


Taille du cercle = PageRank

Classer selon la popularité

À discuter · 4 min

Que pensez-vous de cette façon de choisir les résultats à montrer en premier ? Voyez-vous des dangers ?



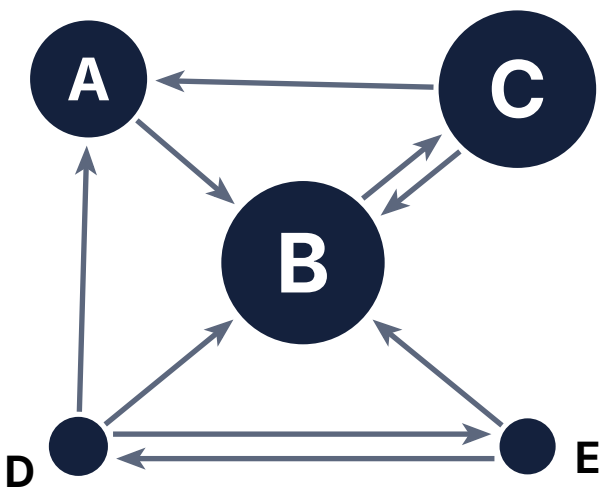
Taille du cercle = PageRank

Classer selon la popularité

Que pensez-vous de cette façon de choisir les résultats à montrer en premier ? Voyez-vous des dangers ?

Cet algorithme récompense les pages **populaires**, celles que les autres sites mettent en avant.

Sur un sujet, la page populaire n'est pas forcément celle qui contient les informations les plus intéressantes, ni les plus justes.



Taille du cercle = PageRank

La personnalisation

Les résultats dépendent aussi de votre profil de visiteur :

Où vous êtes : votre lieu, deviné depuis votre adresse IP.

« pizza » dans Google :

Suisse | ● **1009, Lausanne** — D'après votre adresse IP

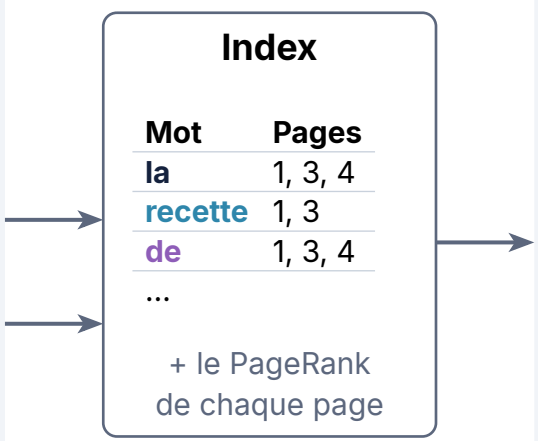
Qui vous êtes : les cookies, votre compte si vous êtes connecté, vos recherches précédentes.

C'est aussi à ce moment que le moteur de recherche choisit les publicités qu'il vous montre.

Résumé : comment ça marche

Avant la recherche

- Le robot lit le contenu des pages et leurs liens
- Il indexe le contenu
- On calcule le PageRank de chaque page
- On recommence, sans arrêt



Au moment de la recherche

- Vous tapez des mots-clés
- Le moteur de recherche charge votre profil
- Il cherche vos mots-clés dans l'index, et classe les pages trouvées selon leur PageRank et votre profil
- Il choisit des publicités ciblées
- Il vous montre les résultats, classés et personnalisés... et les publicités

Sommaire

1

Utiliser un moteur de recherche

À quoi il sert, lesquels, comment s’en servir

2

Comment ça marche ?

Exploration, indexation, classement, personnalisation

3

Et l’IA ?

Une question ouverte

Les assistants IA sont-ils des moteurs de recherche ?

À discuter · 4 min

Les assistants IA (ChatGPT, Gemini, Claude…) sont-ils des moteurs de recherche ?

- D'où viennent leurs connaissances ?
- Comment trouvent-ils une information d'hier ?

Assistants IA et moteurs de recherche

- **Leurs connaissances** viennent du Web, exploré par des robots, comme pour un moteur de recherche : Common Crawl, une exploration publique du Web, et des sites comme Reddit, qui vend ses discussions aux entreprises d'IA.
- **Pour une information récente,** ils font une recherche sur le Web, puis résument les pages trouvées.

Un moteur de recherche

donne des pages classées, qu'on lit soi-même.

Un assistant IA

rédige une réponse, qui peut être fausse, et ne montre pas toujours ses sources.

Sources

Chiffres

Netcraft — le nombre de sites web
netcraft.com

Google — la taille de l'index
google.com

Search Engine Land — 5'000 milliards de recherches par an
searchengineland.com

Search Engine Land — la taille de l'index au procès antitrust
searchengineland.com

Gary Illyes, podcast *Search Off the Record* (Google), décembre 2023 — les robots.txt vérifiés

9to5Google — Google cache le nombre de résultats
9to5google.com

Moteurs et navigateurs

Statcounter — les parts de marché des moteurs de recherche
gs.statcounter.com

AppleInsider — ce que Google paie à Apple
appleinsider.com

OMG! Ubuntu — les revenus de Mozilla
omgubuntu.co.uk

DuckDuckGo — d'où viennent ses résultats
duckduckgo.com

CS Monitor — Google accuse Bing de copier ses résultats
csmonitor.com

Search Engine Journal — Brave Search a son propre index
searchenginejournal.com

Sources

Censure et IA

Wikipedia — Google en Chine
en.wikipedia.org

Brown et al. — les données d'entraînement de GPT-3
arxiv.org

Common Crawl — l'exploration publique du Web
commoncrawl.org

Reuters, février 2024 — l'accord entre Reddit et Google

Images

Dunod — l'index de *Mathématiques Tout-en-un MPSI-MP2I*

Wikimedia Commons, Apple et les sites des moteurs de recherche — les logos

David Iliff — la Long Room du Trinity College, Dublin
commons.wikimedia.org